



Université du Québec
à Chicoutimi

RAPPORT DE STAGE

Maintenance prédictive des ascenseurs

Analyse de données industrielles par apprentissage automatique

Cours : 8INF309 — Stage-Projet I

Réalisé par : Laurent Fabrice Ngwé

Code permanent : NGWL150786

Sous l'encadrement : Dr Aurelien Nicosia

Programme : Baccalauréat en informatique de la science des données et intelligence
d'affaires

Session : Été 2026

Table des matières

1. Introduction

2. Démarches réalisées pour l'obtention du stage

3. Définition du sujet de stage

4. Contexte du stage

4.1 Description de l'entreprise et du milieu de stage

4.2 Superviseur de stage

5. Objectifs du stage

6. Chronologie du stage

7. Déroulement du stage — phases techniques

7.1 Cerner le problème

7.2 Récupérer et examiner les données

7.3 Visualisation et exploration

7.4 Préparation des données pour l'apprentissage automatique

7.5 Sélection et entraînement des modèles

7.6 Optimisation et évaluation finale

8. Analyse du stage — liens avec les cours suivis

9. Impressions personnelles et apport du stage

10. Conclusion

1. Introduction

Le présent document constitue le rapport de stage du cours 8INF309 (Stage-Projet I), réalisé dans le cadre du Baccalauréat en informatique de la science des données et intelligence d'affaires à l'Université du Québec à Chicoutimi (UQAC). Ce stage a porté sur la conception et la mise en œuvre d'un système de maintenance prédictive basé sur l'analyse de données industrielles issues de capteurs positionnels sur un ascenseur.

La maintenance prédictive représente un enjeu stratégique majeur dans l'industrie 4.0 : plutôt que d'intervenir de manière curative après une panne, ou préventive selon un calendrier fixe, elle permet de prédire l'état des équipements en temps réel grâce aux données. Le projet réalisé durant ce stage illustre concrètement la chaîne complète d'un projet de science des données : de l'acquisition des données jusqu'à la comparaison de modèles de Machine Learning en passant par leur nettoyage, leur exploration et leur préparation.

Ce rapport présente les démarches ayant mené à ce stage, le contexte dans lequel il s'est déroulé, la chronologie des activités réalisées, ainsi qu'une analyse critique des apprentissages effectués et de leur lien avec les cours du programme universitaire.

2. Démarches réalisées pour l'obtention du stage

L'obtention de ce stage a nécessité plusieurs étapes de réflexion et de préparation. Dans un premier temps, une analyse personnelle des intérêts professionnels et des compétences acquises en cours de programme a été menée. Cette réflexion a permis d'identifier quatre domaines d'intérêt prioritaires :

- l'intelligence artificielle et l'apprentissage automatique
- l'analyse de données industrielles
- la maintenance prédictive
- les systèmes intelligents et l'industrie 4.0

Par la suite, plusieurs sujets de stage potentiels ont été évalués en fonction de leur pertinence académique, de leur applicabilité aux compétences acquises et de leur valeur professionnelle. Le sujet de maintenance prédictive d'ascenseur a été retenu car il permet l'application directe des techniques d'analyse de données et d'apprentissage automatique dans un contexte industriel réel.

Une phase de recherche documentaire a été menée afin de comprendre les principes de la maintenance prédictive, les systèmes de surveillance industrielle, les méthodes d'analyse de données de capteurs, ainsi que les outils technologiques couramment utilisés dans ce domaine. Le jeu de données public issu de travaux de recherche sur les ascenseurs, disponible sur la plateforme Kaggle et Zenodo (Axenie et Bortoli), a été sélectionné pour sa richesse et sa représentativité industrielle.

3. Définition du sujet de stage

Le stage porte sur le développement d'un système de maintenance prédictive basé sur l'analyse de données de capteurs industriels montés sur un ascenseur. Le jeu de données utilisé contient des séries temporelles échantillonnées à 4 Hz lors des périodes de pointe (16 h 30 à 23 h 30), collectant les valeurs de huit capteurs :

- cinq capteurs de roulement à billes (x1 à x5)
- un capteur d'humidité
- un capteur de vibrations
- un compteur de révolutions

Le projet vise deux objectifs complémentaires. Le premier est une tâche de régression : prédire la valeur absolue des vibrations de l'équipement. Le second est une tâche de classification : déterminer l'état de l'équipement selon les quatre niveaux de sévérité de la norme ISO 10816.

Classe	Seuil de vibration	Sévérité ISO 10816	Action recommandée
A	≤ 20	Bon — équipement neuf	Maintenance standard
B	20 – 40	Satisfaisant — opérationnel	Surveillance normale
C	40 – 70	Non satisfaisant — à surveiller	Inspection dans 48h
D	> 70	Dangereux — arrêt requis	Arrêt immédiat

4. Contexte du stage

4.1 Description de l'entreprise et du milieu de stage

Ce stage s'est déroulé dans un contexte académique

4.2 Superviseur de stage

La supervision du stage a été assurée par le Dr Aurelien Nicosia qui nous a guidé dans la définition du projet, le choix du jeu de données et la structuration de la démarche analytique, tout en évaluant les livrables hebdomadaires et la progression technique.

5. Objectifs du stage

5.1 Objectifs techniques

- Analyser un jeu de données industrielles réelles issues de capteurs d'ascenseur
- Réaliser une exploration visuelle approfondie des données
- Appliquer une Analyse en Composantes Principales (ACP) pour la réduction de dimensionnalité
- Implémenter et évaluer plusieurs modèles de régression (linéaire, Ridge, Lasso, polynomiale, Gradient Boosting)
- Implémenter et évaluer des modèles de classification (Arbre de décision, Random Forest, HistGradientBoosting)
- Optimiser les hyperparamètres par validation croisée (GridSearchCV, RandomizedSearchCV)

5.2 Objectifs professionnels

- Développer l'autonomie dans la conduite d'un projet de données de bout en bout
- Structurer et documenter une démarche analytique rigoureuse
- Renforcer la capacité à justifier des choix méthodologiques
- Consolider les bonnes pratiques de génie logiciel (GitHub, Jupyter, code modulaire, utilisation d'un IDE moderne tel Positron)

6. Chronologie du stage

Semaine	Phase	Activités principales
1	Cerner le problème	Rédaction du projet de stage, recherche documentaire, choix du jeu de données Kaggle/Zenodo
2	Récupérer les données	Mise en place de l'environnement Python, création du dépôt GitHub, chargement et inspection du dataset
3	Visualiser et comprendre	Distributions, boîtes à moustaches, pairplot, matrice de corrélation, partage 80/20, ACP
4	Préparer les données	Étiquetage ISO 10816, suppression des variables redondantes, traitement IQR, RobustScaler
5-6	Entraîner les modèles	Régression linéaire, Ridge, Lasso, arbre de décision, Random Forest, HistGradientBoosting
7	Optimiser et évaluer	Régression polynomiale, GridSearchCV, comparaison finale

7. Déroulement du stage — phases techniques

7.1 Cerner le problème

La première semaine a été consacrée à la définition précise du problème. Le jeu de données sélectionné, publié par Axenie et Bortoli sur Zenodo, contient 110 000 enregistrements de capteurs d'ascenseur. La problématique a été formulée sous deux angles complémentaires : d'abord, un problème de régression visant à prédire la valeur de vibration ; ensuite, un problème de classification visant à catégoriser l'état de l'équipement selon la norme industrielle ISO 10816. Cette double approche permet d'évaluer plusieurs familles d'algorithmes et d'obtenir une vision complète des capacités prédictives des données disponibles.

7.2 Récupérer et examiner les données

La semaine 2 a été dédiée à la mise en place de l'environnement de travail et à l'examen de la structure du jeu de données. L'inspection initiale a révélé que le dataset comprenait 9 variables (ID, revolutions, humidity, x1 à x5, vibration) pour 110 041 observations. L'analyse des valeurs manquantes a identifié 2 438 valeurs absentes dans la variable cible 'vibration' ($\approx 2,2\%$), en deçà du seuil de 5 %, ce qui a justifié leur suppression sans risque de biais significatif. Après nettoyage, le dataset retenu comptait 107 603 observations.

7.3 Visualisation et exploration des données

La semaine 3 a été entièrement consacrée à l'exploration visuelle. Les histogrammes de distribution ont révélé que les variables x1, x2 et x3 présentaient une distribution quasi identique à 'revolutions', suggérant une forte colinéarité. La variable cible 'vibration' s'est avérée fortement asymétrique à droite (skewness élevé). Les boîtes à moustaches ont confirmé la présence de valeurs aberrantes dans 'humidity', 'vibration' et 'x5', justifiant l'utilisation ultérieure du RobustScaler.

La matrice de corrélation a démontré de façon quantitative que x1, x2, x3 et x4 sont corrélées à 'revolutions' à plus de 0,98, et que x5 est corrélée à 'humidity' à pratiquement 1,00. Ces redondances ont conduit à l'application d'une Analyse en Composantes Principales (ACP). Le cercle des corrélations de l'ACP a confirmé visuellement l'alignement de x1–x4 sur l'axe de 'revolutions' et de x5 sur l'axe de 'humidity'. En conséquence, les variables x1 à x5 ont été éliminées, réduisant l'espace des variables de 9 à 3 (ID, revolutions, humidity) sans perte d'information.

7.4 Préparation des données pour l'apprentissage automatique

La semaine 4 a été consacrée à la préparation du jeu de données pour la modélisation. Une fonction d'étiquetage a été créée pour classer chaque observation selon les seuils ISO 10816. La répartition obtenue (classe A : 47 %, B : 31 %, C : 17 %, D : 5 %) a révélé un déséquilibre notable, exigeant l'utilisation du paramètre `class_weight='balanced'` dans les classifieurs.

Les valeurs aberrantes de la variable 'vibration' ont été traitées par la méthode IQR (écart interquartile), supprimant les observations en dehors des limites $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$. La normalisation a été effectuée avec le RobustScaler de scikit-learn, conçu pour résister aux valeurs aberrantes car il utilise la médiane et l'écart

interquartile plutôt que la moyenne et l'écart-type. La division entraînement/test a été réalisée selon un ratio 80/20 avec échantillonnage stratifié sur la variable de classe, garantissant une représentation proportionnelle de chaque classe dans les deux sous-ensembles.

Avant l'application de la régression linéaire, les quatre hypothèses fondamentales ont été vérifiées : linéarité, normalité des résidus, homoscédasticité et absence de multicolinéarité (déjà traitée par l'ACP). Les graphiques de diagnostic (résidus vs valeurs prédites, QQ-plot) ont révélé que la relation entre les prédicteurs et la vibration n'est pas purement linéaire, motivant l'exploration d'algorithmes plus complexes.

7.5 Sélection et entraînement des modèles

Les semaines 5 et 6 ont été dédiées à l'implémentation et à l'évaluation de plusieurs familles d'algorithmes.

Régression

Trois modèles linéaires ont été entraînés et comparés : régression linéaire simple (OLS), régression Ridge (régularisation L2, $\alpha=1$) et régression Lasso (régularisation L1, $\alpha=0,01$). La métrique principale utilisée est le coefficient de détermination R^2 , complété par le RMSE et le MAE. Les trois modèles linéaires ont produit des R^2 similaires et relativement faibles, confirmant l'hypothèse d'une relation non linéaire entre les prédicteurs et la vibration (corrélations $< 0,15$).

Classification

Un arbre de décision et un Random Forest ont été entraînés. La profondeur optimale de l'arbre de décision a été déterminée par validation croisée à 5 plis en maximisant le F1-score pondéré. Le Random Forest (5 000 estimateurs, `class_weight='balanced'`) a surpassé l'arbre de décision sur toutes les métriques, tout en présentant des courbes d'apprentissage convergentes témoignant d'un moindre sur-apprentissage.

Gradient Boosting

Le modèle HistGradientBoostingRegressor (équivalent XGBoost de scikit-learn) a été introduit pour répondre aux limites des modèles linéaires. Contrairement à la régression linéaire qui suppose $y = w \cdot x + b$, le Gradient Boosting construit séquentiellement des arbres de décision sur les résidus, capturant les non-linéarités et les interactions entre variables sans hypothèse préalable. Un RandomizedSearchCV sur la grille d'hyperparamètres (`max_iter`, `max_depth`, `learning_rate`, `min_samples_leaf`) a permis d'identifier la configuration optimale.

7.6 Optimisation et évaluation finale

La semaine 7 a été consacrée à l'optimisation des modèles et à la comparaison finale. La régression polynomiale (Pipeline PolynomialFeatures + Ridge) a été testée pour les degrés 1, 2 et 3 : le degré optimal a produit une amélioration significative du R^2 par rapport à la régression linéaire simple, confirmant la nature non linéaire des relations. Un GridSearchCV sur le Random Forest (paramètres `n_estimators`, `max_depth`, `min_samples_leaf`) a produit le meilleur classifieur.

L'analyse de l'importance par permutation (permutation importance) a permis de déterminer la contribution réelle de chaque variable : mélanger aléatoirement une

variable et mesurer la dégradation de performance est plus fiable que l'importance basée sur l'impureté de Gini.

Famille	Meilleur modèle	Métrique	Résultat
Régression	HistGradientBoosting	R^2 test	Meilleur R^2 obtenu
Régression linéaire	Ridge Polynomial ($d \geq 2$)	R^2 test	Amélioration significative vs linéaire
Classification	Random Forest optimisé	F1-weighted	Meilleur score multi-classe
Classification	HistGradientBoosting	F1-weighted	Comparable au Random Forest

8. Analyse du stage — liens avec les cours suivis

Le stage a mobilisé et intégré de manière systématique les connaissances acquises dans plusieurs cours du programme de Baccalauréat en informatique de la science des données et intelligence d'affaires.

8.1 Analyse de données et statistiques

Les concepts fondamentaux d'analyse statistique exploratoire ont été directement mis en œuvre : calcul et interprétation des statistiques descriptives (moyenne, médiane, écart-type, skewness, kurtosis), détection des valeurs aberrantes par la méthode IQR, analyse de la distribution des variables par histogrammes et KDE, et interprétation de la matrice de corrélation. La transformation logarithmique de la variable cible ($\log_{10}$) pour réduire l'asymétrie est une technique classique enseignée dans les cours de traitement des données.

La vérification des hypothèses de la régression linéaire tel que linéarité, normalité des résidus (test de Shapiro-Wilk, QQ-plot), homoscedasticité (test de Durbin-Watson) et absence de multicollinéarité constitue un exemple concret d'application de la théorie statistique enseignée.

8.2 Apprentissage automatique (Machine Learning)

La totalité du pipeline de Machine Learning a été mise en œuvre : partage des données, évaluation par validation croisée, optimisation des hyperparamètres et interprétation des résultats. Les algorithmes utilisés — régression linéaire, Ridge, Lasso, régression polynomiale, arbre de décision, Random Forest, Gradient Boosting — correspondent aux contenus des cours d'apprentissage automatique du programme. La compréhension des compromis biais-variance, illustrée par les courbes d'apprentissage, est un concept central dans ces cours.

L'utilisation du GridSearchCV et du RandomizedSearchCV pour l'optimisation des hyperparamètres démontre la maîtrise des bonnes pratiques de développement de modèles. La métrique F1-score pondérée a été préférée à l'accuracy pour évaluer les classifieurs en présence de classes déséquilibrées, ce qui reflète une maîtrise des nuances d'évaluation enseignées dans les cours.

8.3 Réduction de dimensionnalité — ACP

L'Analyse en Composantes Principales (ACP) constitue un exemple direct d'application des cours d'algèbre linéaire et de réduction de dimensionnalité. L'ébouillement des valeurs propres, le cercle des corrélations et l'interprétation des chargements (loadings) sont des outils enseignés dans les cours de statistiques multivariées. Dans ce projet, l'ACP a permis de démontrer formellement la redondance des variables x_1 – x_5 et de réduire l'espace des prédictors de 9 à 3 variables.

8.4 Programmation Python et génie logiciel

Les compétences en programmation Python acquises dans les cours d'introduction à la programmation et de structures de données ont été indispensables tout au long du stage. L'utilisation de pandas pour la manipulation des DataFrames, de NumPy pour les calculs vectorisés, de scikit-learn pour les pipelines de ML, et de matplotlib/seaborn pour la visualisation est directement issue des laboratoires de ces

cours. La structuration du code en fonctions réutilisables (`eval_regression()`, `classify_iso()`, `plot_learning_curve()`) témoigne de l'application des principes de conception logicielle enseignés.

8.5 Problèmes rencontrés et solutions apportées

Problème rencontré	Solution apportée
Forte colinearité entre variables (x1–x5)	Application de l'ACP pour identification et suppression des variables redondantes
Valeurs aberrantes dans 'vibration' et 'humidity'	Méthode IQR pour détection + RobustScaler pour normalisation
Classes déséquilibrées (A : 47 %, D : 5 %)	Paramètre <code>class_weight='balanced'</code> et métrique F1-score pondéré
Faible R^2 de la régression linéaire	Régression polynomiale et Gradient Boosting pour capturer la non-linéarité
Optimisation chronophage des hyperparamètres	RandomizedSearchCV à la place de GridSearchCV exhaustif pour l'espace large

9. Impressions personnelles et apport du stage

9.1 Déroulement général et relations humaines

Ce stage a représenté une expérience particulièrement enrichissante, car il a permis de vivre pour la première fois le cycle complet d'un projet de science des données. La progression par semaines thématiques, inspirée de la méthode CRISP-DM (Cross Industry Standard Process for Data Mining), a imposé une rigueur méthodologique bénéfique.

Les interactions avec notre encadreur ont permis de valider les choix méthodologiques à chaque étape et d'approfondir la compréhension de concepts parfois abordés de manière théorique en cours. La rétroaction hebdomadaire a constitué un moteur d'amélioration continue.

9.2 Adaptation technique

Plusieurs adaptations techniques ont été nécessaires au cours du stage. La découverte que les corrélations linéaires entre les prédicteurs et la variable cible étaient très faibles ($< 0,15$) a nécessité une remise en question de l'approche initiale et l'exploration d'algorithmes non linéaires. Cette adaptation a été l'occasion de mieux comprendre les forces et les limites de chaque famille d'algorithmes.

La gestion du déséquilibre des classes dans la tâche de classification a également nécessité une adaptation : la métrique accuracy, initialement considérée, a été remplacée par le F1-score pondéré, plus représentatif dans ce contexte. Cette décision témoigne d'une compréhension approfondie des enjeux d'évaluation des modèles.

9.3 Apport du stage au plan académique et professionnel

- Consolidation de la maîtrise de scikit-learn et de son écosystème (Pipelines, ColumnTransformer, cross_val_score)
- Développement de la rigueur dans la documentation du code et des choix méthodologiques
- Meilleure compréhension des contraintes opérationnelles de la maintenance industrielle
- Renforcement de la capacité à présenter des résultats analytiques sous forme décisionnelle
- Prise de conscience de la valeur de la phase exploratoire dans tout projet de ML

9.4 Pistes d'amélioration identifiées

Ce stage a également permis d'identifier plusieurs axes d'amélioration pour de futurs projets similaires :

- Intégrer des features temporelles (moyenne glissante, dérivée) pour mieux capturer les tendances dans les séries temporelles à 4 Hz

- Explorer des modèles séquentiels (LSTM, 1D-CNN) mieux adaptés aux données temporelles
- Appliquer la technique SMOTE pour augmenter les données de la classe D (5 %) et améliorer la sensibilité sur les pannes critiques
- Mettre en place un système d'alertes automatisé déclenché par les prédictions du modèle

10. Conclusion

Ce premier stage de premier cycle a permis de concrétiser et de consolider les compétences acquises dans notre programme de Baccalauréat en informatique de la science des données et intelligence d'affaires de l'UQAC, en les appliquant à un problème industriel réel de grande pertinence.

Le projet de maintenance prédictive des ascenseurs a démontré la chaîne complète d'un projet de science des données : définition du problème, acquisition et nettoyage des données, exploration visuelle, réduction de dimensionnalité par ACP, préparation des données, entraînement et évaluation de multiples familles d'algorithmes, optimisation par validation croisée. Chacune de ces étapes a mobilisé des connaissances issues de cours spécifiques du programme, démontrant la cohérence entre la formation académique et les exigences du marché professionnel.

Sur le plan des résultats, les principaux constats sont : la relation entre les capteurs et la vibration est non linéaire (justifiant le recours au Gradient Boosting et à la régression polynomiale) ; la réduction de dimensionnalité par ACP élimine cinq variables redondantes sans perte d'information ; et le Random Forest optimisé ainsi que le HistGradientBoostingClassifier produisent les meilleures performances de classification ISO 10816, avec des recommandations opérationnelles concrètes allant de la maintenance standard planifiée (classe A/B) à l'arrêt immédiat (classe D).

Ce stage a représenté une transition importante entre la formation théorique et la pratique professionnelle, confirmant notre intérêt pour les domaines de l'intelligence artificielle appliquée et de la science des données industrielles. Les compétences développées constituent une base solide pour la suite du parcours universitaire et pour l'entrée dans le marché du travail.